

GCI 2026 Summer コンペティション2 — 提出コード説明書

提出者: kesaitou
最終提出: 4 モデルのアンサンブル (XGBoost / LightGBM / ロジスティック回帰 / SVC)。各モデルの予測を順位に変換して単純平均し、交差検証 (k=10) の分割乱数を 100 通り変えた全モデルの予測を平均して安定化
スコア: 交差検証 AUC 0.8892 / Public LB 0.9249

1. 方針 — CV を主な意思決定基準にする

本コンペのデータは train 1,568 行と小さく、Public LB は test の一部での評価のためスコアのばらつき (ノイズ) が大きい。そこで序盤から **Public LB の単発スコアを追いかけるのではなく、交差検証 (CV) を主な採否基準にした**。Public LB は、CV で確認した改善が test 側にも転移するか、また CV 上の改善が過学習でないかを確認する補助情報として使った。結果として、CV と Public LB のスコアの差は全期間を通じて +0.030~0.033 の範囲で安定し、ドメイン特徴量・GBM の再チューニング・k=10 fold といった主要な改善は Public LB でも同方向に反映された。一方で一部の細かいチューニングは CV と LB が食い違ったため、最終構成の選択では過学習の可能性も考慮した。

2. データ理解が検証設計を決めた

EDA で方針を左右する 2 つの構造を確認した。

- 重複データ:** train 1,568 行中、特徴量が完全に一致する行が 90 組・186 行存在した。通常の StratifiedKFold ではこの「双子」の片方が学習側、もう片方が検証側に分かれて入るため、モデルが学習側で暗記した答えをそのまま検証側で当ててしまい、検証スコアが約 +0.003 高めに出る。そこで採否判定には**重複した行を必ず同じ fold に入れるグループ分割の交差検証 (group-CV)** を併用し、暗記による見かけの改善と本物の汎化改善を区別できるようにした (図 1)。
- train / test は同一分布:** adversarial validation (train と test を見分ける分類器) の AUC が $0.483 \approx 0.5$ で、両者は識別不能。よって「CV を信じてよい」ことが確認でき、方針 1 の裏付けになった。




図 1: 重複データ (双子) が検証スコアを水増しする仕組みと、group-CV による対策

さらに改善候補の採否は **2 段階で検証**した。まず分割乱数 (seed) を変えた 5 回の CV で改善候補を洗い出し、次に探索に使っていない別の 11 通りの seed で再検証した。採用の目安は、複数の seed で改善方向が概ね一貫していること、かつ同じ seed 同士で新旧のスコア差を取る対応つき t 検定で「この差が偶然生じる確率 (p 値)」が十分小さいこととし、効果の大きさや改善の理由を説明できるかも合わせて判断した。小データでは seed 1 つ分の CV スコア差 ± 0.003 程度は乱数だけでも生じるため、ノイズを改善と取り違えないようにこの手順を守った。

3. モデル構築の経緯

段階	施策	CV (AUC)	Public LB
ベースライン	LightGBM (生の数値列のみ)	0.8295	—
特徴量	+ ドメイン特徴量 (下記)	0.8706	—
モデル比較	XGBoost + Optuna チューニング	0.8791	—
アンサンブル	XGB + LGBM + LogReg の rank 平均	0.8822	—
4 モデル目を追加	+ SVC (RBF カーネル)	0.8865	0.9173
seed 平均	fold 分割の乱数シードを 17→25→50 通りに増やし全モデルの予測を平均	0.8865	0.9229
再チューニング	Optuna の探索範囲を広げ、group-CV のスコアを目的関数にして GBM を再調整	0.8870	0.9240
fold 数	k=5 → k=10 (各モデルが学習に使える行数が 80% → 90% に増加)	0.8885	0.9249
最終	seed を 100 通りに拡大	0.8892※	0.9249


※ 最終行の CV は 100 seed 分の予測を平均した後に評価した値（バギング後のスコア）。

特徴量設計（寄与最大 +0.041、全施策中で最大）：「どんな顧客がキャンペーンに反応しやすいか」の仮説を先に立て、それを列にする形で設計した。主な仮説と特徴量の対応：

仮説（反応しやすい顧客像）	作った特徴量
優良顧客ほど反応する — 最近も買い、頻度も金額も多い（マーケティングの古典的枠組み RFM）	総消費額、総購入回数、最終購買からの日数 × 消費額・購入回数
高単価カテゴリを好む層が販促のターゲット — ワイン・肉・金製品は嗜好性が強い	高単価カテゴリ消費額とその構成比、肉 × カタログ等の交互作用
家計の余裕が反応を左右する	一人あたり所得（所得 ÷ 世帯人数）、消費額 ÷ 所得
在籍が長いのに最近買っていない顧客は離反気味で反応しにくい	在籍日数あたりの購買速度、最終購買からの日数 ÷ 在籍日数（沈黙度）
チャンネルの使い方に顧客タイプが表れる	カタログ/Web/店舗の構成比、平均注文単価、Web 訪問 → 購入の転換率、割引購入比率

なお全て与えられた列の行単位の演算で、train 統計は所得欠損の中央値補完と在籍日数の基準日のみ（train から算出し test に適用）とし、リークが生じない構成にした。

アンサンブル設計：性質の異なる 4 モデル — 木（XGB/LGBM）× 線形（LogReg）× カーネル（SVC）— を選び、予測の相関を下げて平均の分散低減効果を最大化した。線形・カーネルには木が分岐で自動発見する交互作用（肉×カタログ等の積）を明示的に特徴量として与え、単体性能と多様性を両立させた。評価指標 AUC は予測値の順位のみで決まるため、確率のスケールが異なるモデル同士は、予測値を「全体の中で何番目に高いか」という順位に変換してから 4 モデルで単純平均した（重み付けの最適化も試したが単純平均と有意差がなく、重みが CV に過学習する恐れだけ増えるため単純平均とした）。最終モデルの全体構成を図 2 に示す。



各モデルとも StratifiedKFold k=10 × 乱数シード 100 通り = 1,000 個を学習し、予測を平均（計 4,000 モデル）

図 2: 最終提出モデルの全体構成（モデルごとに特徴量セットを変え、多数モデルの平均で安定化）

多数モデルの平均による安定化：fold 分割の乱数シードを変えた seed × fold の全モデルで test を予測して平均し、一つ一つのモデルが持つ偶然の当たり外れを打ち消した（表中の「seed 平均」）。17→25→50 seed までは Public LB でも改善を確認できた。最終版の 100 seed（計 4,000 モデル）は、50 seed 版とほぼ同じ予測順位を保ちながら分散をさらに下げる「安定化」の位置づけで採用した。

4. 試したが採用しなかったもの

採用した施策の裏で、45 テーマ以上を同じ 2 段階の検証にかけたが、効果を確認できず見送った。主なもの: SMOTE 等の不均衡データ対策、target encoding、テーブルデータ向けニューラルネット（MLP / TabM / FT-Transformer）、Factorization Machine、擬似ラベル、DART、ランキング目的の boosting、学歴などのセグメント別に分けたモデル、重複行の除去（group-CV のスコアがかえって悪化した。重複は test 側にも同じ割合で存在する構造であり、取り除く理由がないと判断した）。効果がなかった施策も記録に残し、同じ系統の施策を繰り返し試さないようにした。

5. 振り返り

振り返ると、個々の手法の工夫以上に、「小データでは CV のスコア自体がぶれ（ノイズ）や実力より高く出る偏り（過大評価）を持つ」ことを前提に、検証のやり方を先に固めたこと（group-CV、探索に使っていない seed での 2 段階の検証、多数モデルの平均）が最も効いたと感じている。おかげで終盤も Public LB の変動に一喜一憂せず、モデルを増やして平均するという確実な改善だけを積み上げて最終提出を決められた。